

II4012 Inteligensi Artifisial untuk Bisnis

Laporan Tugas Besar

RetailMind

Dosen: Dr. Masayu Leylia Khodra, S.T., M.T.



Disusun oleh Kelompok 11

Anggota:

Muhammad Syarafi Akmal	13522076
Mochamad Ikhbar Adiwiningun	18223050
Alghan Pridanusuta	18223058
Vincentia Belinda Sumartoyo	18223078
Kenlyn Tesalonika Winata	18223098

Program Studi Sistem dan Teknologi Informasi

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

2026

DAFTAR ISI

BAB I.....	6
BUSINESS UNDERSTANDING.....	6
1.1 Konteks Bisnis.....	6
1.2 Identifikasi Masalah dan Dampak Operasional.....	6
1.3 Rumusan Masalah.....	6
1.4 Ide Solusi Strategis, Taktis, dan Operasional.....	7
1.5 Tujuan dari Perspektif Klien (Business Goals).....	7
1.6 Batasan dan Asumsi Proyek.....	7
BAB II.....	8
DATA UNDERSTANDING.....	8
2.1 Deskripsi Sumber Data.....	8
2.2 Fitur Krusial Pemodelan RFM.....	8
2.3 Hasil dan Visualisasi Analisis Data Eksploratif.....	8
2.4 Identifikasi Masalah Data.....	11
BAB III.....	12
DATA PREPARATION.....	12
3.1 Data Cleaning.....	12
3.2 Feature Engineering RFM.....	12
3.3 Feature Scaling dan Transformasi.....	13
BAB IV.....	14
MODELLING.....	14
4.1. Arsitektur Pipeline.....	14
4.2 Model Segmentasi Pelanggan (RFM Analysis & Clustering).....	15
4.2.1 Parameter Model dan Konfigurasi.....	15
4.2.2 Integrasi Segmen ke Dasbor Profiling.....	15
4.3 Model Prediksi Churn (Churn Prediction).....	16
4.3.1 Mekanisme Algoritma Isolation Forest.....	16
4.3.2 Parameter Model dan Konfigurasi.....	16
4.4 Model Customer Lifetime Value (CLTV).....	16
4.4.1 Parameter Model dan Konfigurasi.....	16
BAB V.....	18
EVALUATION.....	18
5.1. Evaluasi Segmentasi K-Means.....	18
5.2. Evaluasi Churn Risk Score (Isolation Forest).....	19
5.2.1. Evaluasi Kualitas Intrinsik Model.....	19
5.2.2. Validasi Kelayakan Bisnis.....	20
5.3. Evaluasi Model CLTV - BG/NBD + Gamma-Gamma.....	21
BAB VI.....	22
DEPLOYMENT.....	22
6.1 Hasil Deployment Model Solusi ke Sistem.....	22

6.2 Use Case Diagram Sistem.....	23
6.3 Penjelasan Singkat Fitur Sistem.....	23
DAFTAR REFERENSI.....	25
Lampiran.....	26

DAFTAR TABEL

Tabel 1.1 Identifikasi Masalah dan Dampak RetailMind.....	6
Tabel 1.2 Ide Solusi Strategis, Taktis, dan Operasional.....	7
Tabel 5.1 Hasil Metrik K-Means.....	18
Tabel 5.2 Perbandingan Jumlah Pohon Dan Metrik.....	20
Tabel 5.3 Hasil Metrik CLTV.....	21

DAFTAR GAMBAR

Gambar 2.1 Grafik Distribusi Geografis.....	9
Gambar 2.2 Grafik Tren Penjualan Bulanan.....	9
Gambar 2.3 Grafik Distribusi Kuantitas dan Harga.....	10
Gambar 2.4 Matriks Retensi Cohort.....	10
Gambar 3.1 Perbandingan Data Hasil Tahapan Data Cleaning.....	12
Gambar 3.2 Hasil Proses Feature Engineering.....	13
Gambar 3.4 Hasil Feature Scaling dan Transformasi.....	13
Gambar 4.1 Diagram flowchart arsitektur sistem RetailMind.....	14
Gambar 5.1 Visualisasi Cluster Dengan PCA 2D.....	19
Gambar 6.2.1 Diagram Use Case RetailMind.....	23

BAB I

BUSINESS UNDERSTANDING

1.1 Konteks Bisnis

Pertumbuhan *e-commerce* di Indonesia menyebabkan biaya akuisisi pelanggan (*Customer Acquisition Cost*) terus meningkat, sehingga optimalisasi nilai pelanggan yang sudah ada (*Customer Lifetime Value*) menjadi penting untuk menjaga keberlanjutan bisnis. Studi menunjukkan bahwa peningkatan retensi pelanggan sebesar 5% dapat meningkatkan profit lebih dari 25%. Namun, sebagian besar strategi retensi saat ini masih bersifat reaktif, yaitu dilakukan setelah pelanggan berhenti bertransaksi.

1.2 Identifikasi Masalah dan Dampak Operasional

Terdapat tiga akar masalah utama yang saling berkaitan dan belum terselesaikan secara efisien.

Tabel 1.1 Identifikasi Masalah dan Dampak RetailMind

Akar Masalah	Kondisi Saat Ini	Pendekatan Konvensional	Dampak Bisnis
<i>Silent Churn</i>	~70% pelanggan beralih ke kompetitor tanpa komplain, sistem konvensional baru mendeteksi setelah berbulan-bulan tidak aktif.	Reaktif (baru mendeteksi setelah pelanggan tidak aktif berbulan-bulan)	Potensi pendapatan jangka panjang hilang dan <i>Customer Lifetime Value</i> menurun
<i>Blanket Promotions</i>	Promo diskon didistribusikan merata tanpa klasifikasi loyalitas pelanggan	Distribusi voucher merata tanpa klasifikasi loyalitas pelanggan	Margin bleeding (diskon diberikan ke pelanggan yang tidak memerlukan insentif)
<i>Copywriting Bottleneck</i>	~72% konsumen hanya merespons pesan personal dan tim marketing tidak mampu menulis ribuan variasi pesan secara manual	Pesan tunggal yang sama untuk seluruh pelanggan (<i>mass broadcast</i>)	Tingkat interaksi rendah, pesan rentan ditandai sebagai spam

1.3 Rumusan Masalah

- Bagaimana cara memprediksi pelanggan yang berisiko berhenti bertransaksi (*churn*) lebih awal?
- Bagaimana cara mengelompokkan pelanggan berdasarkan perilaku belanja (*Recency, Frequency, Monetary*/RFM) agar strategi pemasaran lebih tepat sasaran?
- Bagaimana cara menghasilkan pesan promosi yang otomatis dan dipersonalisasi sesuai karakteristik pelanggan dengan memanfaatkan generative AI?
- Bagaimana merancang sistem analitik cerdas yang menggabungkan prediksi churn, segmentasi pelanggan, dan personalisasi promosi untuk meningkatkan retensi pelanggan serta menjaga pendapatan bisnis *e-commerce* menengah di Indonesia?

1.4 Ide Solusi Strategis, Taktis, dan Operasional

Tahap *Business Understanding* pada CRISP-DM berfokus pada perumusan solusi strategis, taktis, dan operasional. Berikut pemetaan solusi RetailMind.

Tabel 1.2 Ide Solusi Strategis, Taktis, dan Operasional

Level	Hipotesis Solusi	Pendekatan AI	Output yang Diharapkan
Strategis	Prediksi dini risiko <i>churn</i> lebih efektif dibandingkan tindakan setelah pelanggan pergi.	Prediksi <i>churn</i> dini dengan model unsupervised learning	<i>Churn risk score</i> (0-100%) per pelanggan yang dapat digunakan sebagai <i>trigger campaign</i> retensi
Taktis	Promosi tersegmentasi mengurangi margin bleeding dan meningkatkan ROI.	Unsupervised Learning (K-Means <i>Clustering</i>) berbasis fitur RFM (<i>Recency, Frequency, Monetary</i>)	Segmen pelanggan (<i>High Value, At Risk, Hibernating, New/Occasional</i>) dengan rekomendasi aksi berbeda per segmen
Operasional	Otomatisasi AI memungkinkan personalisasi pesan dalam skala besar secara efisien.	Generative AI (Gemini API) dengan <i>prompt engineering</i> untuk personalisasi pesan WhatsApp per segmen.	Pesan promosi WhatsApp yang terkirim dan disesuaikan dengan segmen dan promo yang relevan

1.5 Tujuan dari Perspektif Klien (*Business Goals*)

Untuk menjawab permasalahan bisnis yang ada, solusi ini bertujuan meningkatkan retensi pelanggan dan mendukung pertumbuhan bisnis *e-commerce*. Adapun *business goals* yang ingin dicapai adalah:

- Meningkatkan retensi pelanggan melalui deteksi dini risiko *churn*.
- Mengoptimalkan anggaran promosi dengan segmentasi pelanggan yang lebih tepat.
- Meningkatkan efektivitas pemasaran melalui personalisasi promosi.
- Mendukung pengambilan keputusan berbasis data untuk strategi retensi yang lebih akurat.

1.6 Batasan dan Asumsi Proyek

Implementasi proyek memiliki beberapa batasan, seperti ketergantungan pada kuota Fonnte API untuk pengiriman WhatsApp dan Gemini API untuk generasi pesan AI. Selain itu, pada tahap demo atau MVP, kampanye hanya diarahkan ke nomor perwakilan tiap segmen untuk validasi pengiriman pesan. Proyek ini juga mengasumsikan bahwa perilaku *churn* pelanggan dapat dideteksi lebih awal, segmentasi RFM cukup merepresentasikan perilaku pelanggan, pelanggan Indonesia responsif terhadap pesan WhatsApp yang personal, serta sistem dapat digunakan tanpa keahlian *data science* khusus melalui dashboard yang tersedia.

BAB II

DATA UNDERSTANDING

Fokus utama pada tahapan ini adalah memahami karakteristik, struktur, dan kualitas dari dataset yang digunakan. Sesuai dengan pembaharuan arsitektur sistem, data yang digunakan adalah dataset Online Retail II UCI yang diunduh dari Kaggle. Dataset ini merepresentasikan data transaksi historis dari sebuah perusahaan ritel online non-toko yang berbasis di Inggris.

2.1 Deskripsi Sumber Data

- **Sumber Data:** Online Retail II UCI (<https://www.kaggle.com/datasets/mashlyn/online-retail-ii-uci?resource=download>)
- **Konteks Bisnis:** Dataset ini mencatat riwayat transaksi ritel online non-toko yang berbasis di Inggris sepanjang periode pengerjaan proyek. Perusahaan beroperasi dengan model bisnis utama B2B, di mana mayoritas pelanggan setianya adalah pedagang grosir.
- **Format Data:** Format tabular berupa CSV/Excel yang berisi riwayat transaksi pelanggan tingkat baris.

2.2 Fitur Krusial Pemodelan RFM


Untuk membangun arsitektur segmentasi dan memformulasikan matriks perilaku, pemodelan analitik bergantung sepenuhnya pada ekstraksi 4 pilar fitur krusial berikut

1. **Customer ID:** Berfungsi sebagai identifikasi absolut untuk mengonsolidasikan ribuan baris faktur yang tersebar menjadi satu profil metrik tingkat pengguna.
2. **InvoiceDate:** Stempel waktu kalender ini merupakan pondasi utama untuk menghitung jumlah hari sejak interaksi terakhir pelanggan.
3. **Quantity & Price:** Nilai untuk menghasilkan nilai transaksi bruto. Akumulasi dari nilai ini membentuk total pengeluaran bersih pelanggan.
4. **Invoice:** Penghitungan jumlah nomor faktur unik per pelanggan digunakan untuk melacak seberapa sering mereka datang dan berhasil menyelesaikan pesanan.

2.3 Hasil dan Visualisasi Analisis Data Eksploratif

Berdasarkan pengerjaan pada pra-pemrosesan, ditemukan beberapa pola perilaku melalui visualisasi grafik,


1. **Grafik Distribusi Negara**



Gambar 2.1 Grafik Distribusi Geografis

Visualisasi sebaran pesanan menunjukkan dominasi mutlak dari pasar domestik Inggris yang mencakup lebih dari 90% dari total baris transaksi, disusul oleh negara-negara Eropa Barat seperti Jerman, Prancis, dan Belanda.


2. Grafik Tren Penjualan Bulanan



Gambar 2.2 Grafik Tren Penjualan Bulanan

Plot tren volume transaksi memperlihatkan adanya pola musiman yang kuat. Terjadi lonjakan kurva penjualan yang ekstrem pada kuartal keempat khususnya bulan Oktober dan November, yang didorong oleh siklus belanja liburan akhir tahun.


3. Grafik Distribusi Kuantitas dan Harga



Gambar 2.3 Grafik Distribusi Kuantitas dan Harga

Visualisasi histogram menunjukkan sebaran data yang sangat condong ke kanan. Sebagian besar transaksi memiliki kuantitas dan harga satuan yang kecil, namun terdapat outliers transaksi bervolume raksasa khas pelanggan grosir B2B. Grafik ini juga memperjelas eksistensi data kuantitas bernilai negatif akibat retur barang.

4. Matriks Retensi Cohort



Gambar 2.4 Matriks Retensi Cohort

Visualisasi berupa heatmap diagram mengelompokkan pelanggan berdasarkan kuartal atau bulan transaksi pertama mereka. Hasil grafik menunjukkan tingkat retensi cenderung mengalami penurunan melandai pada bulan-bulan awal setelah akuisisi, namun menstabilkan diri pada kelompok pelanggan B2B jangka panjang.

2.4 Identifikasi Masalah Data

Dari pemahaman awal terhadap dataset, ditemukan beberapa pola yang perlu ditangani, yaitu

- **Missing Values:** Terdapat kekosongan data, khususnya pada kolom *Customer ID* dan *Description*. Transaksi tanpa ID pelanggan tidak dapat digunakan untuk agregasi model segmentasi.
- **Anomali Kuantitas dan Harga:** Terdapat nilai *Quantity* yang negatif dan harus digabungkan atau dikurangkan dari total pembelian pelanggan agar nilai *Monetary* tidak bias.
- **Rentang Waktu Transaksi:** Data bersifat *time-series*, sehingga untuk pemodelan *Churn Prediction*, perlu ditetapkan *cut-off date* untuk memisahkan data historis sebagai fitur dan data masa depan sebagai target.

BAB III

DATA PREPARATION

Data preparation dalam CRISP-DM adalah tahap pengolahan data mentah menjadi data yang bersih, terstruktur, dan siap untuk digunakan dalam proses pemodelan *machine learning* agar performa modelnya bagus. Pada tahapan ini, dataset UCI *Online Retail II* yang berisi 1.067.372 data transaksi *e-commerce* akan melewati tiga proses utama *data preparation* berikut:

3.1 Data Cleaning

- **Menghapus baris yang tidak memiliki *Customer ID* (*missing value*)** karena transaksi ini tidak dapat dihubungkan dengan pelanggan tertentu, jadi tidak ada gunanya untuk tetap mempertahankannya.
- **Menghapus transaksi yang dibatalkan** (*invoice*-nya diawali dengan karakter 'C') agar tidak mempengaruhi perhitungan *Frequency* dan *Monetary*.
- **Menghapus data duplikat** karena data yang identik pada seluruh kolom diasumsikan sebagai kesalahan pencatatan sistem yang dapat mempengaruhi nilai *Frequency* dan *Monetary* pelanggan.
- **Memfilter nilai *Quantity* dan *Price* yang kurang dari atau sama dengan nol** karena tidak valid.
- **Mengkonversi tipe data *InvoiceDate* yang awalnya bertipe *string/object* menjadi *datetime*** agar dapat digunakan dalam kalkulasi selisih waktu (*Recency*).

Berikut adalah perbandingan data hasil tahapan cleaning ini:

Jumlah baris	: 1,067,371	Jumlah baris	: 779,425
Customer unik	: 5,942	Customer unik	: 5,878
Invoice unik	: 53,628	Invoice unik	: 36,969
Rentang tanggal	: 2009-12-01 s/d 2011-12-09	Rentang tanggal	: 2009-12-01 s/d 2011-12-09
Missing value per kolom:		Missing value per kolom:	
Invoice	0	Invoice	0
StockCode	0	StockCode	0
Description	4382	Description	0
Quantity	0	Quantity	0
InvoiceDate	0	InvoiceDate	0
Price	0	Price	0
Customer ID	243007	Customer ID	0
Country	0	Country	0
dtype: int64		TotalPrice	0
		dtype: int64	
Baris duplikat	: 34,335	Baris duplikat	: 0
Transaksi pembatalan	: 19,494	Transaksi pembatalan	: 0

Sebelum Cleaning

Sesudah Cleaning

Gambar 3.1 Perbandingan Data Hasil Tahapan Data Cleaning

3.2 Feature Engineering RFM

Proses ini dilakukan untuk membentuk representasi perilaku pelanggan menggunakan metode RFM (*Recency*, *Frequency*, *Monetary*) sebagai dasar segmentasi dan prediksi *customer churn*. **Pertama,**

ditambahkan kolom **TotalPrice** dari hasil perkalian *Quantity* dan *Price*. Lalu, dihitung fitur RFM per pelanggan berdasarkan Customer ID yang telah dibersihkan, di mana *Recency* adalah selisih hari sejak transaksi terakhir, *Frequency* adalah jumlah *invoice*, dan *Monetary* adalah total nilai transaksi.

Fitur RFM kemudian diagregasi per pelanggan dan dikonversi menjadi skor (1–5) menggunakan metode kuantil (`pd.cut()`). Pada *Recency*, skornya dibalik karena nilai lebih kecil menunjukkan pelanggan lebih aktif. Untuk *Frequency*, digunakan `rank(method='first')` sebelum kuantil untuk mengatasi nilai yang sama. Setelah *scoring*, dibentuk RF_Score dari kombinasi *Recency* dan *Frequency* yang kemudian dipetakan ke empat segmen pelanggan yaitu *High Value*, *At Risk*, *Hibernating*, dan *New/Occasional*.

Invoice	StockCode	Description
0 489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS
1 489434	79323P	PINK CHERRY LIGHTS
2 489434	79323W	WHITE CHERRY LIGHTS
3 489434	22041	RECORD FRAME 7" SINGLE SIZE
4 489434	21232	STRAWBERRY CERAMIC TRINKET BOX

Quantity	InvoiceDate	Price	Customer ID	Country
12	2009-12-01 07:45:00	6.95	13085.0	United Kingdom
12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom
12	2009-12-01 07:45:00	6.75	13085.0	United Kingdom
48	2009-12-01 07:45:00	2.10	13085.0	United Kingdom
24	2009-12-01 07:45:00	1.25	13085.0	United Kingdom

	Recency	Frequency	Monetary	
Customer ID	12346.0	326	12	77556.46
12347.0	2	8	4921.53	
12348.0	75	5	2019.40	
12349.0	19	4	4428.69	
12350.0	310	1	334.40	

Data Mentah Sesudah Cleaning

Gambar 3.2 Hasil Proses *Feature Engineering*

3.3 Feature Scaling dan Transformasi

Nilai RFM memiliki rentang skala yang sangat berbeda sehingga perlu dilakukan scaling dan transformasi data untuk menstabilkan distribusi data dan meningkatkan kualitas *clustering*, sesuai dengan model yang digunakan (*Isolation Forest* dan *K-Means*) yang merupakan model berbasis jarak.

- Pada *Isolation Forest* dilakukan ***Standard Scaling*** untuk *Recency*, *Frequency*, dan *Monetary* agar setiap fitur memiliki rata-rata nol dan standar deviasi 1 sehingga kontribusinya seimbang.
- Pada *K-Means* dilakukan transformasi logaritmik $\log(x+1)$ untuk mengatasi distribusi RFM yang *right-skewed*, terutama pada *Frequency* dan *Monetary*. Lalu dilanjutkan dengan *Standard Scaling* untuk menghasilkan dataset `X_log_scaled` sebagai *input K-Means*.

	Recency	Frequency	Monetary	RecencyScore	FrequencyScore	MonetaryScore	RF_Score	
Customer ID	12346.0	326	12	77556.46	2	5	5	25
12347.0	2	8	4921.53	5	4	5	54	
12348.0	75	5	2019.40	3	4	4	34	
12349.0	19	4	4428.69	5	3	5	53	
12350.0	310	1	334.40	2	1	2	21	


Gambar 3.4 Hasil *Feature Scaling* dan Transformasi

BAB IV

MODELLING

Ekosistem analitik RetailMind mengimplementasikan kombinasi metode *unsupervised learning* dan pemodelan statistik probabilistik jangka panjang. Pada tahap ini, model dilatih secara ketat melalui *hyperparameter tuning* untuk meminimalkan *overfitting* dan memastikan stabilitas performa sistem.

4.1. Arsitektur Pipeline



Gambar 4.1 Diagram flowchart arsitektur sistem RetailMind

Diagram di atas memvisualisasikan alur *pipeline inference* terpadu pada sistem RetailMind, yang mengolah data transaksi mentah menjadi wawasan bisnis prediktif melalui tahapan agregasi metrik RFM. Setelah data diagregasi, sistem melakukan pemrosesan secara paralel menggunakan tiga model utama, K-Means untuk segmentasi perilaku, *Isolation Forest* untuk deteksi risiko *churn*, serta model BG-NBD dan Gamma-Gamma untuk estimasi *Customer Lifetime Value*. Seluruh keluaran model kemudian dikalibrasi untuk menentukan ambang batas profil dan dirumuskan ke dalam rekomendasi aksi serta penjelasan berbasis AI yang informatif, yang pada akhirnya disajikan sebagai *dataset* analitik diperkaya melalui *endpoint* REST API untuk kebutuhan dasbor dan aktivasi pemasaran.

4.2 Model Segmentasi Pelanggan (*RFM Analysis & Clustering*)

Model ini bertujuan untuk mengidentifikasi profil perilaku dari pelanggan berbasis metrik riwayat Recency, Frequency, dan Monetary. Karena distribusi data sangat skewed, fitur RFM ditransformasikan secara logaritmik ($\log(x + 1)$) dan *StandardScaler* sebelum pemodelan,

- **Recency:** Jumlah hari sejak pembelian terakhir pelanggan, dihitung dari tanggal referensi terbaru di dataset.
- **Frequency:** Total frekuensi jumlah transaksi/faktur unik yang dilakukan oleh pelanggan.
- **Monetary:** Total nilai uang yang dihabiskan oleh pelanggan.

4.2.1 Parameter Model dan Konfigurasi

Penyetelan konfigurasi untuk algoritma K-Means ditetapkan berdasarkan iterasi validasi,

- **n_clusters=4:** Parameter utama yang dipilih berdasarkan titik tekukan pada Elbow Method dan perolehan skor maksimal pada evaluasi Silhouette Coefficient.
- **init='k-means++':** Teknik digunakan untuk mempercepat konvergensi algoritma dan memastikan hasil clustering yang optimal dan stabil.
- **n_init=10 & max_iter=300:** Algoritma dijalankan 10 kali dengan titik awal centroid berbeda, dengan maksimal 300 iterasi per putaran.
- **random_state=42:** Diterapkan untuk menjaga reproduktibilitas klaster pada setiap proses retraining.

4.2.2 Integrasi Segmen ke Dashbor Profiling

Berdasarkan hasil pemodelan, keempat klaster tersebut diklasifikasikan ke dalam segmen bisnis berikut,

- **High Value:** Kelompok pelanggan inti yang paling berharga, rutin bertransaksi dengan frekuensi tinggi, dan menghasilkan nilai ekonomi terbesar bagi perusahaan. Segmen ini merupakan tulang punggung arus kas bisnis.
- **At Risk:** Pelanggan dengan jejak pembelian masa lalu yang signifikan, namun memiliki *recency* yang memburuk. Segmen ini adalah target akuisisi retensi utama untuk mencegah kerugian finansial jangka panjang.
- **New/Occasional:** Pelanggan yang interaksinya masih tergolong baru atau hanya berbelanja sesekali, namun frekuensi dan volume belanjanya belum setinggi segmen *High Value*. Segmen ini memiliki potensi besar untuk di-upsell.
- **Hibernating:** Pelanggan dengan seluruh metrik (R, F, M) yang berada di bawah standar wajar perusahaan; sangat jarang bertransaksi dan sudah lama pasif.

4.3 Model Prediksi Churn (*Churn Prediction*)

Karena ketidakpastian label pada data ritel, pemodelan ini menggunakan algoritma Isolation Forest untuk memisahkan pelanggan yang menunjukkan anomali perilaku penghentian interaksi secara prediktif.

4.3.1 Mekanisme Algoritma Isolation Forest

Model ini beroperasi dengan membangun *Isolation Trees*. Intinya adalah pelanggan yang akan churn menunjukkan penyimpangan perilaku ekstrem, seperti berhentinya siklus belanja grosir secara mendadak. Penyimpangan ini akan terisolasi sangat cepat di struktur awal pohon karena secara mendasar berbeda dari kelompok aktif.

4.3.2 Parameter Model dan Konfigurasi

Tuning pada Isolation Forest difokuskan pada tingkat sensitivitas deteksi untuk mencegah terjadinya alarm churn yang palsu pada dasbor,

- **contamination=0.15:** Nilai ini dikalibrasi sesuai dengan rata-rata tingkat churn alami di industri B2B, yang berarti model mengasumsikan hanya ~15% dari total observasi yang merupakan outlier.
- **n_estimators=100:** Membangun ensemble sebanyak 100 pohon secara independen. Asumsi cukup optimal untuk menstabilkan probabilitas Risk Score yang dihasilkan tanpa membebani komputasi secara berlebihan.
- **max_samples='auto':** Memastikan panjang sampel dari sub-sampling data diatur secara otomatis ke basis ukuran sampel logaritmik, sesuai dengan karakteristik pohon anomali.

Model memproses fitur-fitur ini menjadi *Anomaly Score* murni, yang kemudian distandardisasi menjadi metrik visibilitas bisnis berwujud *Risk Score*. Hasil probabilitas makro ini diintegrasikan menjadi proyeksi tren ancaman pada grafik komponen, memberikan pandangan strategis bagi manajemen terkait persentase penyusutan pelanggan dalam 6 bulan ke depan.

4.4 Model Customer Lifetime Value (CLTV)

CLTV dirancang untuk menghitung estimasi nilai valuasi finansial masa depan untuk 12 bulan ke depan menggunakan pendekatan model lifetimes probabilistik.

4.4.1 Parameter Model dan Konfigurasi

Kedua sub-model CLTV disetel menggunakan parameter penalti untuk menjaga fungsi generalisasi,

- **Model BG/NBD:** Model untuk prediksi frekuensi masa depan. Parameter tuning utama adalah **penalizer_coef**. Regularisasi L2 ini ditambahkan secara khusus untuk memberikan penalti

terhadap parameter saat fitting distribusi, sehingga model kebal terhadap *overfitting* yang sering terjadi pada pelanggan dengan *cohort* kecil atau jumlah *repeat purchases* yang sangat minim.

- **Model Gamma-Gamma:** Model untuk prediksi nilai masa depan. Serupa dengan BG/NBD, parameter **penalizer_coef** digunakan untuk memperlancar probabilitas dari observasi rata-rata profit pelanggan, mengasumsikan tidak adanya kolerasi absolut antara besaran uang dan frekuensi.

BAB V

EVALUATION

5.1. Evaluasi Segmentasi K-Means


Customer disegmentasi menggunakan algoritma *K Means* dengan fitur RFM (*recency, frequency, monetary*) yang telah ditransformasi log untuk mengatasi distribusi skewed, kemudian *discale* dengan *StandardScaler*. Jumlah cluster optimal ($k=4$) ditentukan dengan *elbow method*.

Tabel 5.1 Hasil Metrik K-Means

Metrik	Nilai	Interpretasi
Silhouette Score	0.365	Baik, cluster cukup terpisah untuk data retail yang noisy
Davies-Bouldin Index	0.930	Cukup baik, nilai < 1.0 menunjukkan cluster kompak dan terpisah
Calinski-Harabasz Score	5061.7	Sangat tinggi, pemisahan antar cluster sangat terdefinisi

Ketiga metrik ini secara konsisten mengindikasikan kualitas segmentasi yang baik:

- ***Silhouette Score*** 0.365 melampaui threshold umum (0.25) untuk data retail, yang secara inheren noisy karena variasi perilaku customer yang luas. Nilai ini menunjukkan bahwa sebagian besar customer berada lebih dekat ke centroid clusternya sendiri dibanding cluster lain.
- ***Davies bouldin index*** 0.930 berada dibawah nilai 1.0, mengindikasikan bahwa cluster bersifat kompak secara internal dan terpisah satu sama lain, kondisi yang cukup ideal untuk segmentasi bisnis
- ***Calinski-Harbasz score*** 5061.7 yang tinggi mengonfirmasi bahwa variance antar cluster jauh lebih besar dibanding variance di dalam cluster, membuktikan pemisahan yang tajam.



Gambar 5.1 Visualisasi Cluster Dengan PCA 2D

Model K-Means menghasilkan 4 segmen customer yang valid secara **statistik**. Ketiga metrik evaluasi secara konsisten mendukung kualitas segmentasi, menjadikan hasil ini dapat dijadikan dasar strategi marketing yang terdiferensiasi.

5.2. Evaluasi Churn Risk Score (Isolation Forest)

Model Isolation Forest (IF) digunakan sebagai pendekatan **unsupervised anomaly detection** untuk mengidentifikasi customer berisiko churn berdasarkan anomali perilaku RFM. Preprocessing menggunakan *raw StandardScaler* pada fitur Recency, Frequency, dan Monetary untuk mempertahankan pencilaan asli. Skor anomali asli dinormalisasi dan dibalik ke skala 0–100:

5.2.1. Evaluasi Kualitas Intrinsik Model

Untuk membuktikan bahwa Isolation Forest adalah model anomali yang stabil, konvergen, dan tidak overfitting terhadap noise pohon keputusan, dilakukan uji kualitas intrinsik:

- Uji stabilitas skor via bootstrapping

Model dilatih sebanyak 5 kali menggunakan sampel *bootstrap* acak (80% dari dataset). Stabilitas antar model diuji menggunakan *spearman rank correlation* pada risiko seluruh populasi. Rata rata dari korelasi spearman adalah **0.9348** yang artinya model sangat konsisten dan tidak sensitif terhadap variasi kecil atau noise pada train set

- Analisis Konvergensi Jumlah Pohon (*n_estimator*)

Diuji selisih rata rata MAE dari *anomaly score* pada berbagai ukuran *forest* dibandingkan dengan benchmark *forest* penuh (500 pohon)

Tabel 5.2 Perbandingan Jumlah Pohon Dan Metrik

Jumlah Pohon	Selisih MAE vs Benchmark
10	0.01747
30	0.00759
50	0.00797
100	0.00472
200	0.00262
300	0.00207

Deviasi MAE menyusut sangat signifikan di bawah 0.005 pada ukuran 100 pohon, membuktikan model sangat efisien dan stabil secara matematis pada $n_estimator = 100$

5.2.2. Validasi Kelayakan Bisnis

Untuk membuktikan bahwa anomali yang diisolasi oleh model sejalan dengan pemahaman logika bisnis tentang churn, dilakukan pengujian korelasi dan spasial

- Uji separasi jarak geometris

Pelanggan dikelompokkan ke dalam 3 tier risiko berdasarkan *churn_risk_score*. Dihitung jarak *euclidean* pelanggan ke *normal centroid* (rata rata pelanggan low risk) di ruang RFM terstandarisasi:

- Rata rata jarak ke centroid normal:
 - Low Risk (<30): **0.881**
 - Medium Risk (30-70): **1.973**
 - High Risk (>=70): **9.045**
- Uji Statistik (T-test)
 - T-statistic = **8.367**
 - P-value = 4.721×10^{-12}
- Interpretasi

Pelanggan *high risk* secara statistik terbukti merupakan **pencilan spasial sejati** yang terisolasi 9 kali lipat jauh dari populasi normal di ruang RFM

- Korelasi *Risk score vs Recency*

Pengukuran Korelasi Pearson antara skor risiko dari model Isolation Forest dengan variabel *Recency* menunjukkan nilai positif sebesar 0.208. Nilai positif ini secara umum sejalan dengan asumsi bisnis dasar bahwa semakin lama pelanggan tidak bertransaksi, risiko *churn* cenderung ikut meningkat. Namun, besaran korelasi linier yang tergolong lemah ini justru memberikan *insight* krusial: indikasi *churn* pelanggan tidak bersifat linier sederhana dan tidak dapat diprediksi hanya dengan melihat keterbaruan transaksi (*Recency*) saja. Temuan ini secara kuat memvalidasi urgensi penggunaan algoritma multidimensional dan non-linier seperti Isolation Forest. Model ini terbukti mampu mengidentifikasi anomali *churn* yang lebih kompleks, berdasarkan interaksi antara *Recency*, *Frequency*, dan *Monetary* secara bersamaan, yang akan luput jika hanya menggunakan analisis linier atau aturan ambang batas (*threshold*) tradisional.

5.3. Evaluasi Model CLTV - BG/NBD + Gamma-Gamma

Model *customer lifetime value* menggunakan pendekatan probabilistik dua tahap:

1. BG/NBD (Beta Geometric/Negative Binomial Distribution) memodelkan frekuensi dan kemungkinan customer masih aktif
2. Gamma-Gamma memodelkan nilai transaksi rata rata per customer

Evaluasi dilakukan dengan ***holdout validation***, data dibagi menjadi periode kalibrasi (untuk training) dan periode *holdout* (untuk testing), kemudian frekuensi transaksi prediksi dibandingkan dengan aktual

Tabel 5.3 Hasil Metrik CLTV

Metrik	Nilai	Interpretasi
MAE	1.087 transaksi	Rata rata selisih prediksi vs aktual ~1 transaksi

MAE 1.087 artinya model memprediksi frekuensi transaksi customer di periode *holdout* dengan rata rata meleset sekitar 1 transaksi dari nilai aktual. Untuk model probabilistik yang hanya menggunakan data historis R/F/T tanpa fitur eksternal seperti demografi, *seasonality*, atau campaign data, performa ini cukup dapat diterima dan konsisten dengan benchmark umum model BG/NBD pada dataset retail e-commerce.

BAB VI

DEPLOYMENT

Tahapan deployment pada framework CRISP-DM bertujuan untuk mengimplementasikan hasil pemodelan ke dalam sistem yang dapat digunakan oleh pengguna akhir. Pada proyek RetailMind, model machine learning yang telah dikembangkan diintegrasikan ke dalam aplikasi dashboard analitik pelanggan untuk membantu tim bisnis melakukan segmentasi pelanggan, memprediksi risiko churn, memperkirakan customer lifetime value (CLTV), serta menghasilkan pesan komunikasi promosi yang lebih personal.

6.1 Hasil Deployment Model Solusi ke Sistem

Pada implementasinya, model hasil training diintegrasikan ke dalam aplikasi RetailMind sebagai komponen inferensi otomatis. Sistem menerima data transaksi pelanggan, kemudian menjalankan proses preprocessing berupa pembentukan fitur RFM (*Recency, Frequency, Monetary*) dan transformasi data sesuai konfigurasi model yang telah digunakan pada tahap pelatihan. Setelah itu, sistem menjalankan inferensi terhadap model-model berikut:

1. Model Segmentasi Pelanggan (K-Means)

Model K-Means digunakan untuk mengelompokkan pelanggan ke dalam beberapa kategori perilaku pelanggan seperti *High Value, At Risk, New/Occasional*, dan *Hibernating*. Hasil segmentasi ditampilkan pada dashboard untuk membantu tim marketing menentukan strategi promosi yang sesuai untuk setiap kategori pelanggan.

2. Model Prediksi Risiko Churn (Isolation Forest)


Model Isolation Forest digunakan untuk menghasilkan *churn risk score* pelanggan berdasarkan pola perilaku transaksi. Skor ini digunakan sebagai indikator pelanggan yang berpotensi berhenti bertransaksi sehingga tim bisnis dapat melakukan tindakan preventif lebih awal melalui promosi atau kampanye retensi pelanggan.

3. Model Customer Lifetime Value (CLTV)

Model BG/NBD dan Gamma-Gamma digunakan untuk memperkirakan nilai ekonomi pelanggan pada periode mendatang. Informasi ini membantu perusahaan memprioritaskan pelanggan bernilai tinggi dan menentukan alokasi promosi secara lebih efektif.

Selain model analitik, sistem juga terintegrasi dengan modul generative AI untuk menghasilkan pesan promosi yang dipersonalisasi berdasarkan segmentasi pelanggan dan tingkat risiko churn. Dengan pendekatan ini, hasil inferensi model tidak hanya menjadi insight visual pada dashboard, tetapi juga dapat langsung diterjemahkan menjadi tindakan operasional pemasaran.

6.2 Use Case Diagram Sistem



Gambar 6.2.1 Diagram Use Case RetailMind

Pada Gambar 6.2.1 Diagram Use Case RetailMind di atas, pengguna utama sistem adalah tim marketing atau admin yang berinteraksi secara langsung dengan dashboard RetailMind. Pengguna dapat memasukkan data transaksi pelanggan, melihat hasil segmentasi pelanggan, memonitor risiko churn dan estimasi CLTV, serta menghasilkan pesan promosi otomatis berbasis AI berdasarkan kategori segmentasi pelanggan.

6.3 Penjelasan Singkat Fitur Sistem

Retail Mind memiliki beberapa fitur untuk mendukung keputusan berbasis data, yaitu:

1. Customer Segmentation Dashboard

Menampilkan hasil segmentasi pelanggan berdasarkan perilaku pembelian menggunakan metode RFM dan algoritma K-Means. Dashboard membantu memahami karakteristik pelanggan dan menentukan strategi pemasaran yang lebih tepat sasaran.

2. Churn Risk Monitoring

Menampilkan tingkat risiko churn pelanggan berdasarkan hasil inferensi model Isolation Forest dalam bentuk *risk score*, sehingga pelanggan berisiko tinggi dapat diprioritaskan untuk program retensi.

3. Customer Lifetime Value Prediction

Memberikan estimasi nilai pelanggan pada periode mendatang untuk membantu perusahaan menentukan prioritas pelanggan dan efisiensi alokasi promosi.

4. AI Personalized Promotion Generator

Menghasilkan pesan promosi berbasis generative AI yang disesuaikan dengan segmen pelanggan, kondisi churn, dan konteks pemasaran sehingga komunikasi menjadi lebih personal.

5. Integrated Analytics Dashboard

Menyatukan seluruh hasil analitik ke dalam satu dashboard sehingga tim bisnis dapat melakukan monitoring pelanggan dan pengambilan keputusan tanpa memerlukan keahlian data science khusus.

DAFTAR REFERENSI

Bain & Company. (2001). *Prescription for cutting costs: Loyal relationships*. Diakses dari:

https://media.bain.com/Images/BB_Prescription_cutting_costs.pdf

Turkeconom. (2025). *Churn pelanggan: Ancaman bisnis yang tak boleh diabaikan*. Diakses dari:

<https://turkeconom.com/churn-pelanggan/>

Salesso. (2025). *17 Personalized email marketing statistics that will transform your campaigns in 2026*.

Diakses dari: <https://salesso.com/blog/personalized-email-marketing-statistic/>

Lampiran

Github Repo : https://github.com/kenlyn270/II4012_RetailMind

Link Video :  Video Tubes AI RetailMind.mp4